

Ataques de envenenamiento de conocimiento a sistemas KG-RAG

Reproducción del pipeline de ataque en caja negra de Zhao et al. (arXiv:2507.08862)

Ingrid Alicia Yábar Geldres

Universidad Nacional de Ingeniería (UNI)
Facultad de Ingeniería Económica, Estadística y Ciencias Sociales
Doctorado en Ciencias e Ingeniería Estadística
ORCID: 0009-0003-9729-3259 ingrid.yabar.g@uni.pe

Contenido

- 1 Motivación
- 2 Marco teórico
- 3 Método de ataque implementado
- 4 Réplica del experimento
- 5 Desviaciones y limitaciones
- 6 Conclusiones

¿Por qué importa la seguridad de KG-RAG?

- RAG permite que un LLM responda apoyándose en una fuente de conocimiento externa, en lugar de depender solo de lo memorizado en el entrenamiento.
- Cuando esa fuente es un **grafo de conocimiento (KG)**, el sistema puede seguir cadenas de razonamiento explícitas y auditables entre entidades: KG-RAG.
- La misma propiedad que hace útil a un KG-RAG — un grafo editable y actualizable — es también su punto débil.
- Una sola tripleta falsa, bien conectada a la entidad correcta, puede desviar una cadena de razonamiento multi-salto completa, sin alterar visiblemente el resto del grafo.

Pregunta

¿En qué país se filmó la película *Manchester By The Sea*?

Antes del ataque

Manchester By The Sea → filmPlace →
Manchester
Manchester → locatedIn →
Massachusetts
Massachusetts → stateOf → United
States

Después de insertar 1 arista falsa

Manchester → containedIn → England
England → containedIn → United
Kingdom
⇒ el sistema puede responder *United
Kingdom*

Objetivo de esta presentación: documentar una implementación propia de este ataque, de extremo a extremo, sobre un caso verificable a mano.

Grafo de conocimiento y caminos de relaciones

Grafo de conocimiento

$G = (E, R, T)$, con $T \subseteq E \times R \times E$ el conjunto de tripletas (e_h, r, e_t) : una arista dirigida y etiquetada de e_h a e_t .

Camino de razonamiento y camino de relaciones

$p : e_0 \xrightarrow{r_1} e_1 \xrightarrow{r_2} \dots \xrightarrow{r_l} e_l \Rightarrow$ camino de relaciones asociado $w = (r_1, r_2, \dots, r_l)$ (se descartan las entidades intermedias, se conserva solo la secuencia de relaciones).

Anclaje (*grounding*)

Operación inversa: dado un camino de relaciones w y una entidad de inicio, encontrar las entidades reales del grafo alcanzadas al recorrer w .

Pipeline de un sistema KG-RAG

Etapas de recuperación

$$G_q = \text{Retriever}(q; G) \quad (1)$$

Extrae del grafo completo G el subgrafo G_q relevante para la pregunta q .

Etapas de generación

$$a = f_{\theta}(\text{Prompt}[q, G_q]) \quad (2)$$

El LLM f_{θ} produce la respuesta final a partir de q y G_q .

Vulnerabilidad

Si G contiene tripletas falsas bien conectadas, la recuperación puede incluirlas en G_q sin distinguirlas de las legítimas.

$$\hat{A} = \text{KG-RAG}(q; \hat{G}), \quad a^* \notin \hat{A}, \quad \hat{G} = \{E, R, T \cup \hat{T}\} \quad (3)$$

- El atacante **no** conoce el recuperador, el LLM, ni la respuesta correcta a^* de la pregunta atacada.
- Su única capacidad es **insertar** un conjunto pequeño de tripletas $\hat{T}$ en el grafo — no puede borrar ni modificar nada.
- Restricciones de sigilo: cada tripleta insertada reutiliza entidades y relaciones *ya existentes* en el grafo, y el número de tripletas por respuesta adversaria está acotado por un presupuesto K .

Formalización: extracción de caminos de relaciones

$$\max_{\theta} \mathbb{E}_{w \sim W^*} [\log P_{\theta}(w \mid q)] \quad (4)$$

$$\arg \max_{\theta} \frac{1}{|W^*|} \sum_{w \in W^*} \log P_{\theta}(w \mid q) \quad (5)$$

$$\frac{1}{|W^*|} \sum_{w \in W^*} \log \prod_{i=1}^{|w|} P_{\theta}(r_i \mid r_{<i}, q) \quad (6)$$

- W^* : caminos de relaciones más cortos entre la entidad tema y la respuesta correcta (supervisión débil).
- La Ec. 6 descompone el problema: generar un buen camino equivale a predecir, relación por relación, la siguiente relación más plausible.
- El artículo original resuelve esto **entrenando** un LLM específico de KG (LLM_RoG). Esta implementación logra el mismo efecto sin entrenamiento (ver sección de desviaciones).

$$E_{l-1} = \text{Grounding}(e_q, w'; G), \quad w' = (r_1, \dots, r_{l-1}) \quad (7)$$

- Se ancla el **prefijo** del camino desde la entidad tema e_q .
- Por cada entidad alcanzada $e_{l-1} \in E_{l-1}$, se construye la tripleta de perturbación $(e_{l-1}, r_l, \hat{a})$, adjuntando la última relación del camino hacia la respuesta adversaria $\hat{a}$.
- **Estrategia de respaldo:** si el prefijo no se puede anclar, se sintetiza una cadena con entidades puente aleatorias que preserva el mismo patrón de relaciones hasta llegar a $\hat{a}$.

Pipeline de tres etapas

Etapa	Módulo	Salida
1. Respuestas adversarias	<code>adversarial_answers.py</code>	$\hat{A}$ (entidades del KG)
2. Caminos de relaciones	<code>relation_paths.py</code>	plantillas w
3. Inserción de perturbación	<code>perturbation.py</code>	tripletas nuevas

Orquestación

`run_attack(kg, question, topic_entity, llm, n_answers=5, budget_k=4)` encadena las tres etapas y devuelve el grafo envenenado.

Etapas 1 — Generación de respuestas adversarias

```
Question: {question}
```

```
Generate 5 entity names that are incorrect answers to this  
question, but might sound plausible or confusing.
```

- Only list the entity names as a bullet list.
- Each bullet should contain the name of one entity only.

- Prompt tomado de Zhao et al. (2025).
- El LLM puede alucinar nombres que no existen en el grafo.
- Se repiten rondas de generación y se aplica **coincidencia difusa** (`difflib.get_close_matches`) contra el vocabulario de entidades del grafo hasta reunir N respuestas válidas.

Etapas 2 — Extracción de caminos de relaciones

- Se calcula el vocabulario de relaciones alcanzables en pocos saltos desde la entidad tema (`neighborhood_relations`).
- Se le pide al LLM caminos de relaciones usando **solo** ese vocabulario, con un prompt **propio de esta implementación** (el artículo resuelve esta etapa con un modelo entrenado, no con un prompt).
- Cualquier camino propuesto que use una relación fuera del vocabulario se descarta en el post-procesamiento.

Por qué funciona

Restringir el vocabulario garantiza caminos anclables en el grafo real, sin necesidad de entrenar un modelo específico de KG.

Etapas 3 — Inserción de tripletas de perturbación

Estrategia principal

- Ancla el prefijo del camino desde la entidad tema.
- Adjunta la última relación hacia la respuesta adversaria.
- Presupuesto K tripletas por respuesta adversaria.
- Nunca se duplica una triplete ya existente en el grafo.

Estrategia de respaldo

- Si el prefijo no ancla, muestrea entidades puente al azar.
- Preserva el mismo patrón de relaciones del camino.

Entorno

```
pip install -r requirements.txt
cp .env.example .env # completar OPENAI_API_KEY

python scripts/demo_manchester.py --offline
python -m pytest -q
```

- Grafo construido a mano: 13 tripletas sobre *Manchester By The Sea*.
- Modo `-offline`: LLM simulado y determinista, sin llamadas a la API.
- 18 pruebas automatizadas cubren cada etapa de forma aislada, también offline.

Resultado reproducible (modo offline)

```
Adversarial target answers: ['United Kingdom']
Relation path templates: [('filmPlace', 'locatedIn'), ('starring', 'bornIn')]

Injected perturbation triples:
  (Manchester, locatedIn, United Kingdom) [target: United Kingdom]
  (Casey Affleck, bornIn, United Kingdom) [target: United Kingdom]

Poisoned KG: 15 triples (+2 vs. clean)
```

- De los candidatos generados, solo *United Kingdom* ya existía en el grafo: (England, containedIn, United Kingdom), alcanzable en dos saltos desde David Beckham y sin relación con la película.
- Ambos caminos se anclaron directamente: no fue necesaria la estrategia de respaldo.

- Con solo **2 tripletas insertadas** sobre 13 originales, se crean dos rutas de razonamiento alternativas hacia una respuesta incorrecta:
 - Manchester By The Sea → filmPlace → Manchester → locatedIn → United Kingdom
 - Manchester By The Sea → starring → Casey Affleck → bornIn → United Kingdom
- Ninguna señal estructural distingue estas rutas de la ruta legítima hacia *United States*.
- Confirma, a pequeña escala, el mecanismo central del artículo: una perturbación mínima puede activar una cadena de inferencia engañosa completa.
- `pytest -q` ⇒ **18 passed** — cada etapa se valida de forma aislada y reproducible.

Ejecución con la API real de OpenAI

```
Adversarial target answers: ['Florida']  
Relation path templates: [('filmPlace', 'locatedIn'), ('filmPlace', 'starring')]  
  
Injected perturbation triples:  
  (Manchester, locatedIn, Florida) [target: Florida]  
  (Manchester, starring, Florida) [target: Florida]  
  
Poisoned KG: 15 triples (+2 vs. clean)
```

- Modelo real (gpt-4o-mini, sin -offline): la respuesta adversaria cambia de *United Kingdom* a *Florida* —coincidencia accidental distinta, vía (Miami, locatedIn, Florida)— porque el LLM no es determinista.
- El camino (filmPlace, starring) es **anclable pero semánticamente incoherente**: adjuntar starring a una ubicación no tiene sentido real, aunque la restricción de vocabulario lo admite.
- Límite honesto: esta corrida no es reproducible byte a byte; el modo -offline sigue siendo la referencia fija.

Resultados reportados en el artículo original

Método (WebQSP)	F1 limpio	F1 atacado	Caída relativa
RoG	70.34	38.06	↓ 46 %
GCR	71.07	63.94	↓ 10 %
G-retriever	52.39	46.31	↓ 12 %
SubgraphRAG	66.94	50.22	↓ 18 %

- Con solo $N=5$ respuestas adversarias y $K=4$ tripletas cada una (máx. 20 tripletas por pregunta), los cuatro sistemas KG-RAG sufren caídas sustanciales frente a una línea base de modificación aleatoria (caída marginal).
- Hallazgo clave: la vulnerabilidad principal está en la etapa de **recuperación** (cobertura $>90\%$ de tripletas adversarias recuperadas); la etapa de generación es más resistente, pero exhibe una respuesta polarizada — o rechaza el contenido adversario por completo, o lo adopta predominantemente.

Desviaciones frente al método original

Extracción de caminos sin modelo entrenado

El artículo entrena LLM_RoG (LLaMA-2-7B) con el objetivo de las Ec. 4–6. Esta implementación logra caminos anclables restringiendo el vocabulario de relaciones de un LLM de propósito general al vecindario real de la entidad tema — sin GPU ni entrenamiento.

El resto sigue el artículo directamente

Generación de respuestas adversarias por coincidencia difusa e inserción de perturbación con estrategia de respaldo se implementan tal como se describen en el artículo.

- No se integra ningún sistema KG-RAG objetivo (RoG, GCR, G-retriever, SubgraphRAG): la validación se detiene en el grafo envenenado, sin medir métricas de respuesta final (Hit, F1, A-MRR, ...).
- Sin benchmarks a gran escala: un grafo de 13 tripletas construido a mano, frente a los miles de preguntas y subgrafos de WebQSP/CWQ.
- Modelo de lenguaje distinto: gpt-4o-mini en lugar de GPT-4.

Trabajo futuro: integrar un recuperador y generador mínimos para medir el efecto sobre la respuesta final; ejecutar sobre un subconjunto real de WebQSP/CWQ.

- Se reprodujo el pipeline de ataque de tres etapas de forma ejecutable y verificable, con 18 pruebas automatizadas y una demostración de extremo a extremo.
- El caso replicado confirma el mecanismo central del artículo: una perturbación mínima e indistinguible estructuralmente puede activar una cadena de inferencia engañosa completa.
- La principal simplificación — prescindir de un modelo entrenado específico de KG a favor de una restricción de vocabulario — preserva la propiedad esencial (camino anclables) sin requerir entrenamiento, pero no garantiza coherencia semántica: la ejecución real contra la API lo mostró con un camino anclable aunque semánticamente extraño.
- Próximo paso natural: cerrar la brecha hacia el artículo integrando un sistema KG-RAG objetivo para medir el impacto sobre la respuesta final.

Zhao, T., Chen, J., Ru, Y., Zhu, H., Hu, N., Liu, J., & Lin, Q. (2025). *RAG safety: Exploring knowledge poisoning attacks to retrieval-augmented generation*. arXiv.
<https://arxiv.org/abs/2507.08862>

¡Gracias!